

RELATÓRIO DETALHADO — PROBLEMA DE NEGÓCIO

Projeto de Análise de Entregas | Etapa SQL concluída → preparação para Power BI

Objetivo: registrar o problema de negócio, as 18 perguntas analíticas, os resultados, insights e desafios encontrados durante a investigação.

1. Problema de negócio

A empresa fictícia analisada atua em logística e precisa acompanhar a eficiência das entregas. O principal problema é a ocorrência de pedidos entregues fora do prazo, que pode gerar insatisfação, retrabalho, custos e dificuldades de planejamento.

O desafio do Analista de Dados Jr. foi transformar dados operacionais em evidências para responder **onde, quanto, quando e em quais grupos/canais** os atrasos são mais relevantes.

Problema central: entender o comportamento dos atrasos e identificar pontos críticos que merecem investigação e possíveis ações de melhoria.

2. Objetivos

- Medir volume e taxa de atraso.
- Comparar equipes/grupos.
- Identificar cidades críticas.
- Avaliar equipe × cidade.
- Comparar canais.
- Avaliar evolução mensal.
- Investigar lead time previsto × atraso.
- Preparar evidências para o dashboard executivo.

3. Preparação e modelagem

A base foi reorganizada em uma estrutura relacional com uma tabela fato e dimensões. Foi criada a **vw_pedidos_completos**, reunindo os dados por JOIN e calculando lead_time_previsto e lead_time_real com DATEDIFF.

Tabela	Função
fato_pedidos	Pedidos, datas, status e chaves.
dim_cliente	Clientes e nomes.
dim_vendedor	Vendedor e equipe_entrega.
dim_cidade	IDs das cidades.
dim_canal	Canais de entrega.

4. Indicadores gerais

Indicador	Resultado
Total de pedidos	53.656
Atrasados	6.942
Taxa geral de atraso	12,94%
Antecipados	37.968
No prazo	8.746

Lead time previsto médio	3,96 dias
Lead time real médio	2,84 dias
Atraso médio dos atrasados	2,07 dias
Maior atraso	20 dias

5. As 18 perguntas de negócio

1 — Qual é o perfil geral da operação?

Análise: Conhecer volume, período, categorias e qualidade antes de aprofundar a investigação.

Resultado: A análise estabeleceu a linha de base da operação e mostrou a importância de entender os dados antes de interpretar indicadores.

Insight: Começar pela compreensão da base reduz o risco de conclusões precipitadas.

2 — Como os pedidos estão distribuídos?

Análise: Distribuição dos pedidos nas dimensões disponíveis.

Resultado: Alguns grupos, cidades e canais concentram grande parcela do volume.

Insight: A concentração operacional ajuda a definir prioridades.

3 — Qual é o volume por equipe/grupo?

Análise: COUNT(*) agrupado por equipe_entrega.

Resultado: Norte, Sudeste e Nordeste estão entre os maiores volumes; também existem Internet, Televentas, Sul, Distribuidores, Venda Direta e Pronta Entrega.

Insight: A coluna equipe_entrega mistura regiões e categorias de natureza diferente, uma limitação de modelagem.

4 — Qual é o status geral das entregas?

Análise: Contagem por status_entrega.

Resultado: Antecipado 37.968; No Prazo 8.746; Atrasado 6.942. Total 53.656; taxa de atraso 12,94%.

Insight: O atraso é relevante e passa a ser o principal foco da investigação.

5 — Como os atrasos se comportam por grupo?

Análise: Volume, atrasados e taxa por equipe/grupo.

Resultado: Internet 27,42%; Sul 17,99%; Televentas 17,46%; Norte 12,48%; Sudeste 7,47%; Nordeste 6,63%.

Insight: Taxa proporcional e volume absoluto precisam ser analisados juntos.

6 — Quais grupos concentram mais atrasos?

Análise: Ranking pela quantidade absoluta de atrasados.

Resultado: Norte 1.838; Internet 1.598; Sul 1.287; Sudeste 997. Juntos, cerca de 82,4% dos atrasos.

Insight: Priorizar pelo impacto absoluto pode ser diferente de priorizar pela maior taxa.

7 — Quais grupos têm maior risco proporcional?

Análise: Ranking pela taxa, considerando o tamanho da amostra.

Resultado: Internet 27,42%; Venda Direta 21,18%; Sul 17,99%; Televentas 17,46%. Pronta Entrega 100%, mas só 1 pedido.

Insight: Percentuais extremos com amostras pequenas exigem cautela.

8 — Qual o lead time previsto versus realizado?

Análise: Média de lead_time_previsto e lead_time_real.

Resultado: Previsto 3,96 dias; real 2,84 dias; diferença média -1,12 dia.

Insight: Uma média melhor que o previsto não significa ausência de atrasos.

9 — Qual a severidade dos atrasos?

Análise: Apenas pedidos atrasados: média, mínimo e máximo.

Resultado: 6.942 atrasados; atraso médio 2,07 dias; mínimo 1; máximo 20 dias.

Insight: Frequência e severidade são dimensões diferentes do problema.

10 — Como a severidade varia entre grupos?

Análise: Atrasados, atraso médio e maior atraso por grupo.

Resultado: Sul: média 2,41 e máximo 20; Televendas 2,38 e máximo 20; Internet 2,15 e máximo 16; Norte 1,87 e máximo 13.

Insight: Norte tem grande frequência; Sul apresenta maior severidade média.

11 — Quais cidades concentram maior volume?

Análise: COUNT(*) por id_cidade.

Resultado: 79: 8.648; 52: 5.505; 71: 4.179; 25: 3.126; 17: 3.034. Top 5 ≈45,6% dos pedidos.

Insight: Concentração territorial torna esses locais relevantes para capacidade e desempenho.

12 — Quais cidades têm maior volume de atrasos?

Análise: Total, atrasados e taxa por cidade.

Resultado: Cidade 79 teve 587 atrasos; 25 teve 387; 52 318; 71 302; 47 297. Cidade 137 teve 216 atrasos e 24,60%.

Insight: Maior volume não significa maior taxa de risco.

13 — Quais cidades têm maior taxa considerando volume mínimo?

Análise: Filtro de pelo menos 500 pedidos.

Resultado: 68: 53,49%; 137: 24,60%; 77: 17,80%; 47: 16,19%; 110: 14,78%.

Insight: Cidade 68 é um ponto crítico; cidade 25 também merece atenção pelo volume absoluto de atrasos.

14 — Existem combinações críticas equipe × cidade?

Análise: Cruzamento com mínimo de 100 pedidos e taxa de atraso.

Resultado: Internet+131: 97,97%; Internet+118: 95,08%; Norte+88: 59,28%; Internet+68: 55,06%.

Insight: Há associações críticas específicas que merecem investigação; isso não prova causalidade.

15 — Quais canais apresentam maior volume e atraso?

Análise: Volume, atrasados, taxa e lead time por canal.

Resultado: Canal07: 9.132 pedidos, 1.978 atrasos, 21,66%. Canal05: 22,40%. Canal13: 68,60% com 86 pedidos. Canal12 e Canal18: 0 atrasos em 9.086 e 6.899 pedidos.

Insight: Canal07 é prioritário pelo impacto; canais sem atrasos podem servir como benchmarks após validação.

16 — Como volume e taxa evoluem no tempo?

Análise: Volume e atraso por ano/mês.

Resultado: Out/2019 teve maior volume: 3.628. Nov/2019 teve maior taxa: 19,86% e 603 atrasos. Abr/2020: 19,11%; Dez/2019: 18,38%. Ago/2020: 4,47%, possivelmente parcial.

Insight: Há variação temporal importante; o último mês exige cautela.

17 — Quais grupos apresentam recorrência de problemas?

Análise: Equipe × ano × mês, com mínimo de 50 pedidos.

Resultado: Internet teve vários meses acima de 25%, chegando a 38,52% em nov/2019. Sul chegou a 31,98% em abr/2020. Televendas também teve vários períodos acima de 22%.

Insight: Recorrência sugere hipóteses de problemas persistentes, mas não demonstra causa.

18 — Existe relação entre lead time previsto e atraso?

Análise: Faixas de lead time previsto.

Resultado: 5–6 dias: 244 pedidos, 85 atrasados, 34,84%. 3–4: 53.102, 6.837, 12,88%. 7+: 310, 20, 6,45%. Não houve registros até 2 dias.

Insight: A faixa 5–6 dias teve maior taxa, mas a amostra é pequena; não é possível afirmar causalidade.

6. Principais descobertas consolidadas

- 12,94% dos 53.656 pedidos estão atrasados.
- Norte concentra o maior número absoluto de atrasos; Internet apresenta taxa elevada.
- Sul combina frequência relevante e maior severidade média entre os principais grupos.
- Cidades 68, 137, 77 e 47 aparecem como pontos críticos entre cidades com pelo menos 500 pedidos.
- Algumas combinações equipe × cidade apresentam taxas extremamente altas, principalmente envolvendo Internet.
- Canal07 possui o maior impacto absoluto de atrasos; Canal13 possui taxa alta com baixo volume.
- Novembro/2019, dezembro/2019 e abril/2020 são períodos de atenção.
- A média do lead time não explica sozinha o problema: a operação pode ter média real inferior ao previsto e ainda possuir milhares de atrasos.

7. Desafios encontrados

- 1. Modelagem:** foi necessário transformar uma base simples em fato + dimensões e criar uma VIEW para facilitar as consultas.
- 2. Dimensão cidade incompleta:** dim_cidade possui somente id_cidade, sem nome, UF ou região; isso impede análise geográfica nominal.
- 3. Categorias heterogêneas:** equipe_entrega mistura regiões com categorias como Internet e Televidas, dificultando a interpretação semântica.
- 4. Taxa × volume:** foi necessário aprender a não usar somente percentuais ou somente quantidades para definir prioridade.
- 5. Amostras pequenas:** grupos/canais com poucos pedidos podem gerar taxas extremas que não representam um padrão estrutural.
- 6. Média × distribuição:** lead time médio pode esconder atrasos individuais e valores extremos.
- 7. Associação × causalidade:** uma taxa alta em canal, cidade ou período indica uma associação a investigar, não uma causa comprovada.
- 8. Período parcial:** agosto/2020 é o último mês da base e pode não representar um mês completo.

8. Limitações e melhorias futuras

- Enriquecer cidades com nome, UF e região.
- Separar região, canal, equipe e tipo de operação em dimensões adequadas.
- Validar a regra de status_entrega.
- Investigar os canais com zero atraso.
- Analisar distribuição do lead time, não somente média.
- Validar pontos críticos com informações operacionais antes de recomendar ações definitivas.

9. Preparação para o Power BI

A etapa SQL já transformou o problema em evidências. No Power BI, o objetivo será criar uma narrativa executiva que responda rapidamente: **qual é a taxa de atraso, onde estão os problemas, quais pontos têm maior impacto e como o comportamento evolui no tempo?**

A construção será planejada antes dos gráficos: primeiro KPIs, filtros, páginas e perguntas executivas; depois escolha dos visuais.

10. Conclusão executiva

A operação possui 53.656 pedidos e 6.942 atrasos, com taxa geral de 12,94%. Os problemas não estão distribuídos uniformemente. Norte possui grande impacto absoluto, Internet apresenta taxa elevada, Sul combina frequência e severidade, e determinados destinos e combinações operacionais possuem níveis críticos.

A principal conclusão é que o problema deve ser analisado por **volume, taxa, severidade, grupo, cidade, canal e tempo**. A etapa SQL também mostrou que qualidade e modelagem dos dados são essenciais para evitar interpretações equivocadas.

O projeto está, portanto, pronto para avançar ao Power BI com perguntas, evidências, hipóteses e limitações claramente documentadas.